



Politechnika
Wrocławska

Temat pracy

Opracowanie systemu diagnostyki akustycznej maszyn przemysłowych z wykorzystaniem zaawansowanych technik analizy dźwięku i sztucznej inteligencji

Wrocław 2025



HR EXCELLENCE IN RESEARCH

Autor pracy: Damian Jarczok
Promotor pracy: dr inż. Piotr Staroniewicz
Recenzent pracy: dr inż. Maurycy Kin



Wprowadzenie – problematyka i inspiracja

Dlaczego diagnostyka akustyczna maszyn jest potrzebna?


- **Awarie maszyn generują wysokie koszty** – zarówno finansowe, jak i operacyjne, związane z przestojami produkcyjnymi.
- **Tradycyjne metody diagnostyki są niewystarczające** - bazują na okresowych pomiarach, które mogą nie wychwycić wczesnych symptomów usterek.
- **Sygnały akustyczne zawierają bogate informacje diagnostyczne** - zmiany dźwięku mogą wskazywać na konkretne typy uszkodzeń.
- **Mikrofony umożliwiają niedrogą, bezkontaktową i ciągłą rejestrację sygnałów** - również w trudno dostępnych lokalizacjach.

Cel pracy i zakres zrealizowanych działań

Zasadnicze elementy projektu

Cel pracy i zakres zrealizowanych działań

Zasadnicze elementy projektu




System diagnostyczny

- Wykonano system rejestrujący dźwięk, przetwarzający go w czasie rzeczywistym i klasyfikujący usterki za pomocą sieci neuronowych.


Cel pracy i zakres zrealizowanych działań

Zasadnicze elementy projektu



System diagnostyczny

- Wykonano system rejestrujący dźwięk, przetwarzający go w czasie rzeczywistym i klasyfikujący usterki za pomocą sieci neuronowych.




Interfejs użytkownika

- Opracowano graficzny interfejs umożliwiający konfigurację systemu, monitorowanie klasyfikacji i odbieranie powiadomień.


Cel pracy i zakres zrealizowanych działań

Zasadnicze elementy projektu



System diagnostyczny

- Wykonano system rejestrujący dźwięk, przetwarzający go w czasie rzeczywistym i klasyfikujący usterki za pomocą sieci neuronowych.



Interfejs użytkownika

- Opracowano graficzny interfejs umożliwiający konfigurację systemu, monitorowanie klasyfikacji i odbieranie powiadomień.




Stanowisko testowe

- Wykonano fizyczne urządzenie, służące do rejestracji danych i testowania działania systemu w warunkach zbliżonych do rzeczywistych.


Cel pracy i zakres zrealizowanych działań

Zasadnicze elementy projektu



System diagnostyczny

- Wykonano system rejestrujący dźwięk, przetwarzający go w czasie rzeczywistym i klasyfikujący usterki za pomocą sieci neuronowych.




Interfejs użytkownika

- Opracowano graficzny interfejs umożliwiający konfigurację systemu, monitorowanie klasyfikacji i odbieranie powiadomień.



Stanowisko testowe


- Wykonano fizyczne urządzenie, służące do rejestracji danych i testowania działania systemu w warunkach zbliżonych do rzeczywistych.





Eksperymenty i optymalizacja

- Przeprowadzono serię testów skuteczności systemu oraz analizę wpływu parametrów na jakość klasyfikacji.

Główna zasada działania systemu (konwolucyjnych sieci neuronowych)



Metodologia pomiarów – układ pomiarowy






Prezentacja programu



Prezentacja programu




Najważniejsze wnioski – jakość systemu

Najważniejsze wnioski – jakość systemu

**Bardzo wysoka
skuteczność
klasyfikacji**


Osiągnięto bezbłędną 100%
skuteczność w klasyfikacji binarnej
oraz 99,6% w wieloklasowej.



Najważniejsze wnioski – jakość systemu

Bardzo wysoka skuteczność klasyfikacji

Osiągnięto bezbłędną 100% skuteczność w klasyfikacji binarnej oraz 99,6% w wieloklasowej.



Stabilność działania w różnych konfiguracjach


Niezależnie od długości próbek i parametrów sieci – model nie traci znacznie na skuteczności.



Najważniejsze wnioski – jakość systemu

Bardzo wysoka skuteczność klasyfikacji

Osiągnięto bezbłędną 100% skuteczność w klasyfikacji binarnej oraz **99,6%** w wieloklasowej.



Stabilność działania w różnych konfiguracjach

Niezależnie od długości próbek i parametrów sieci – **model nie traci znacznie na skuteczności.**



Doskonała zdolność do generalizacji


Skuteczne działanie także na rzeczywistych danych spoza zbioru treningowego.



Najważniejsze wnioski – jakość systemu

Bardzo wysoka skuteczność klasyfikacji

Osiągnięto bezbłędną 100% skuteczność w klasyfikacji binarnej oraz **99,6%** w wieloklasowej.



Stabilność działania w różnych konfiguracjach

Niezależnie od długości próbek i parametrów sieci – **model nie traci znacznie na skuteczności.**



Doskonała zdolność do generalizacji

Skuteczne działanie także na rzeczywistych danych spoza zbioru treningowego.



Prosta architektura, wysokie wyniki


Decyzje takie jak użycie GMP czy mała liczba MFCC zapewniły **wysoką skuteczność bez dużej złożoności.**



Najważniejsze wnioski – jakość systemu

Bardzo wysoka skuteczność klasyfikacji

Osiągnięto bezbłędną 100% skuteczność w klasyfikacji binarnej oraz **99,6%** w wieloklasowej.



Stabilność działania w różnych konfiguracjach

Niezależnie od długości próbek i parametrów sieci – **model nie traci znacznie na skuteczności.**



Doskonała zdolność do generalizacji

Skuteczne działanie także na rzeczywistych danych spoza zbioru treningowego.



Prosta architektura, wysokie wyniki

Decyzje takie jak użycie GMP czy mała liczba MFCC zapewniły **wysoką skuteczność bez dużej złożoności.**




Gotowość do zastosowań przemysłowych

Parametry działania umożliwiają **wdrożenie do pracy z rzeczywistymi systemami utrzymania ruchu.**



Najważniejsze wnioski – parametry a wynik



Najważniejsze wnioski – ciekawe obserwacje

Najważniejsze wnioski – ciekawe obserwacje

Gwałtowny spadek skuteczności przy 3 warstwach CNN

- Model z 3 warstwami znacząco tracił jakość ($F1 \approx 0,33$), mimo że poprzednie konfiguracje działały dobrze. To nietypowy i niespotykany efekt.

Najważniejsze wnioski – ciekawe obserwacje

Gwałtowny spadek skuteczności przy 3 warstwach CNN

- Model z 3 warstwami znacząco tracił jakość ($F1 \approx 0,33$), mimo że poprzednie konfiguracje działały dobrze. To nietypowy i niespotykany efekt.

Brak dropout poprawia skuteczność

- Całkowita rezygnacja z dropout dawała lepsze wyniki niż jakiegokolwiek jego poziom – wbrew dominującej praktyce w uczeniu głębokim.

Najważniejsze wnioski – ciekawe obserwacje

Gwałtowny spadek skuteczności przy 3 warstwach CNN

- Model z 3 warstwami znacząco tracił jakość ($F1 \approx 0,33$), mimo że poprzednie konfiguracje działały dobrze. To nietypowy i niespotykany efekt.

Brak dropout poprawia skuteczność

- Całkowita rezygnacja z dropout dawała lepsze wyniki niż jakiegokolwiek jego poziom – wbrew dominującej praktyce w uczeniu głębokim.

Global Max Pooling kluczowy dla jakości modelu

- Zamiast Flatten, zastosowanie GMP2D przyniosło niemal idealne wyniki ($F1 \approx 0,9948$), zapobiegając przeuczeniu.

Najważniejsze wnioski – ciekawe obserwacje

Gwałtowny spadek skuteczności przy 3 warstwach CNN

- Model z 3 warstwami znacząco tracił jakość ($F1 \approx 0,33$), mimo że poprzednie konfiguracje działały dobrze. To nietypowy i niespotykany efekt.

Brak dropout poprawia skuteczność

- Całkowita rezygnacja z dropout dawała lepsze wyniki niż jakiegokolwiek jego poziom – wbrew dominującej praktyce w uczeniu głębokim.

Global Max Pooling kluczowy dla jakości modelu

- Zamiast Flatten, zastosowanie GMP2D przyniosło niemal idealne wyniki ($F1 \approx 0,9948$), zapobiegając przeuczeniu.

10 współczynników MFCC działało najlepiej

- Zredukowanie liczby współczynników MFCC do 10 poprawiało generalizację – wbrew standardowemu podejściu (20-40 lub nawet więcej cech).

Najważniejsze wnioski – ciekawe obserwacje

Gwałtowny spadek skuteczności przy 3 warstwach CNN

- Model z 3 warstwami znacząco tracił jakość ($F1 \approx 0,33$), mimo że poprzednie konfiguracje działały dobrze. To nietypowy i niespotykany efekt.

Brak dropout poprawia skuteczność

- Całkowita rezygnacja z dropout dawała lepsze wyniki niż jakkolwiek jego poziom – wbrew dominującej praktyce w uczeniu głębokim.

Global Max Pooling kluczowy dla jakości modelu

- Zamiast Flatten, zastosowanie GMP2D przyniosło niemal idealne wyniki ($F1 \approx 0,9948$), zapobiegając przeuczeniu.

10 współczynników MFCC działało najlepiej

- Zredukowanie liczby współczynników MFCC do 10 poprawiało generalizację – wbrew standardowemu podejściu (20-40 lub nawet więcej cech).

Augmentacja szumem pogarszała wyniki

- Dodanie nawet niewielkiego szumu znacząco obniżało skuteczność modelu – to sprzeczne z ogólnie przyjętym przekonaniem o korzyściach z dodania hałasu.

Kierunki dalszego rozwoju projektu



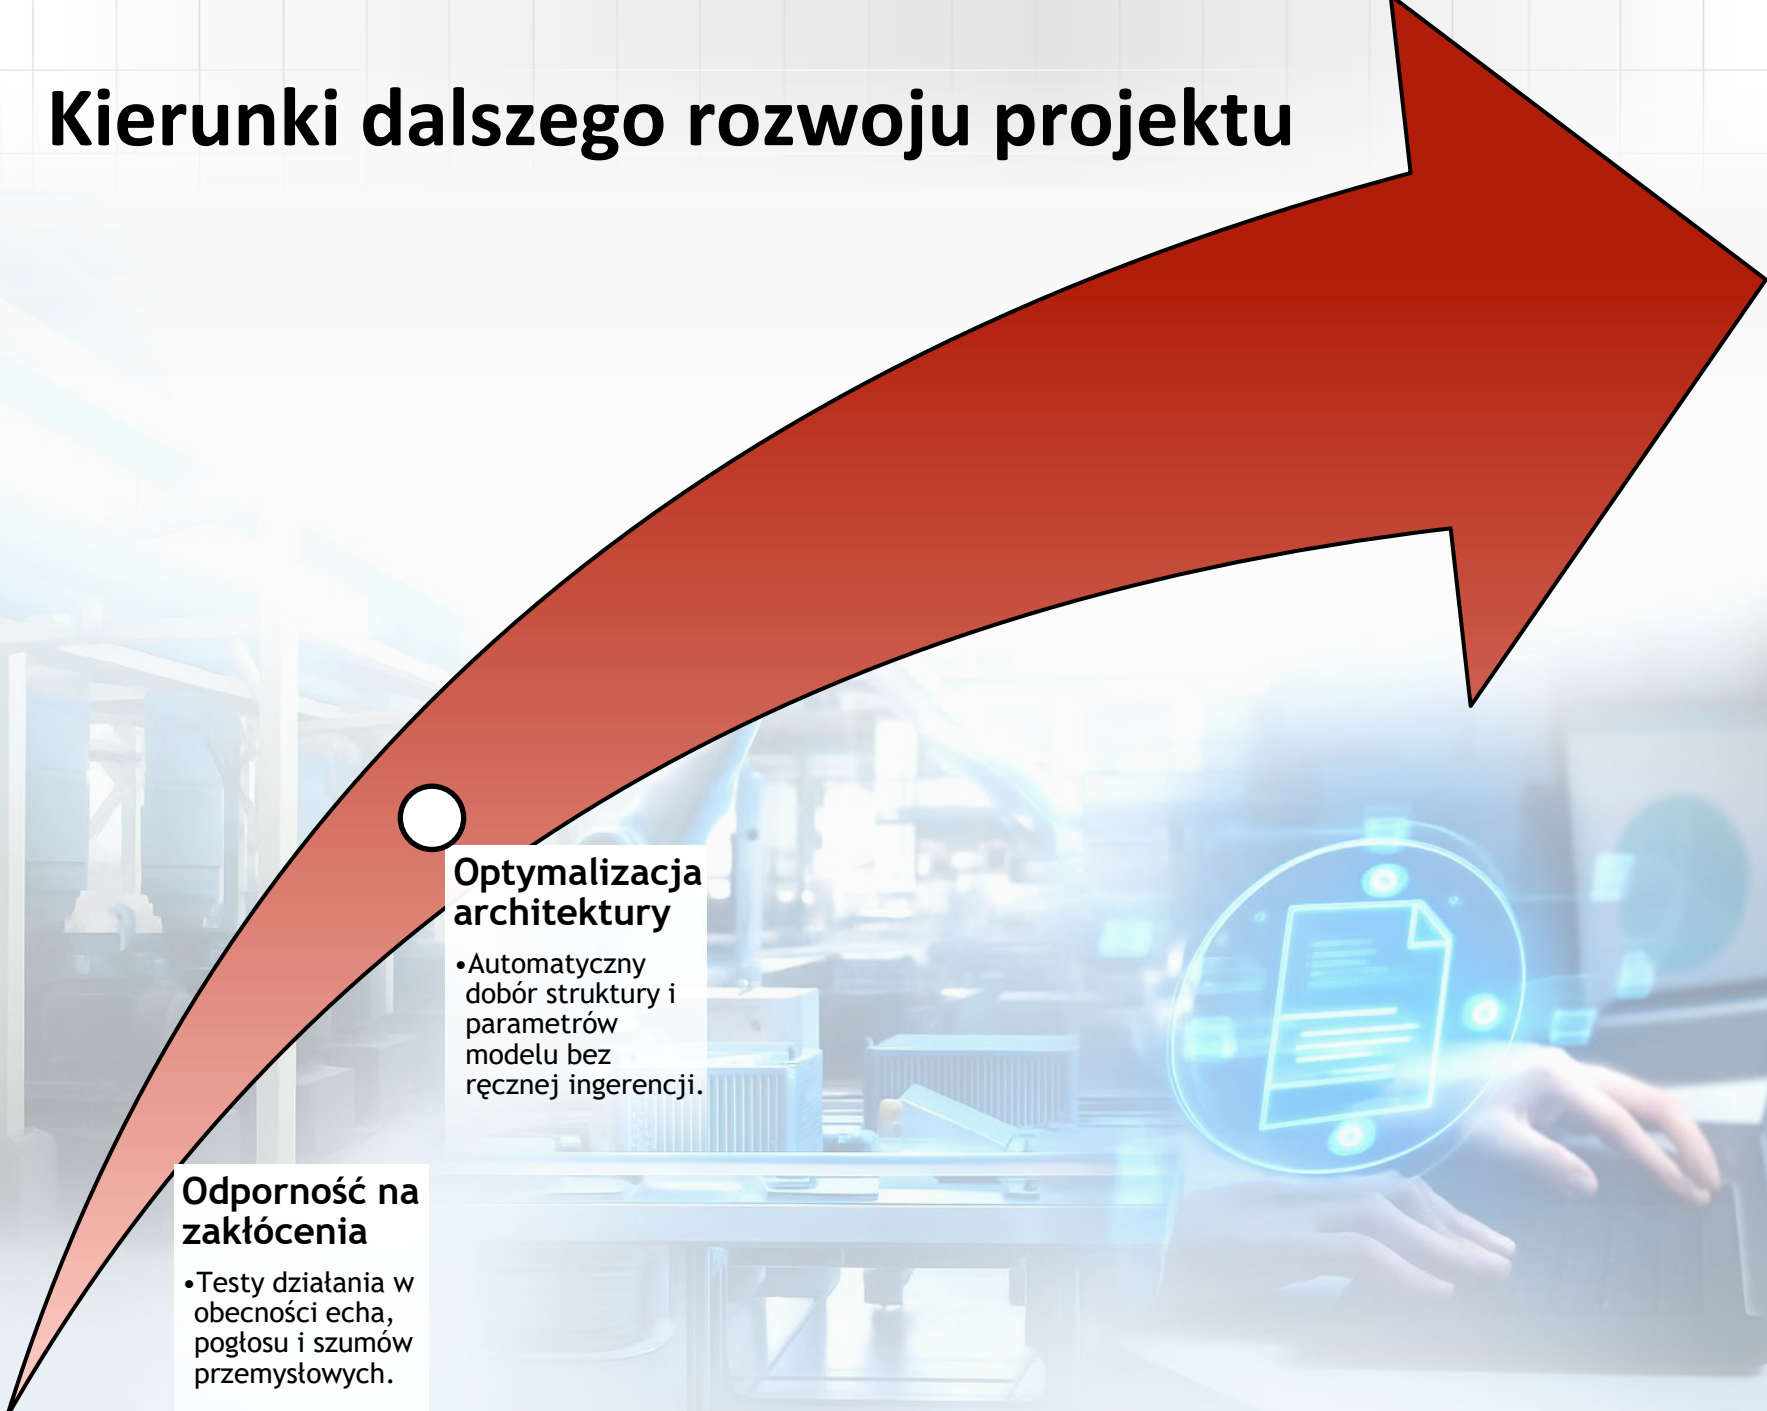
Kierunki dalszego rozwoju projektu



Odporność na zakłócenia

- Testy działania w obecności echa, pogłosu i szumów przemysłowych.

Kierunki dalszego rozwoju projektu



Optymalizacja architektury

- Automatyczny dobór struktury i parametrów modelu bez ręcznej ingerencji.

Odporność na zakłócenia

- Testy działania w obecności echa, pogłosu i szumów przemysłowych.

Kierunki dalszego rozwoju projektu



Integracja z przemysłem

- Kompatybilność z systemami SCADA, MQTT, Modbus i pracą w czasie rzeczywistym.

Optimalizacja architektury

- Automatyczny dobór struktury i parametrów modelu bez ręcznej ingerencji.

Odporność na zakłócenia

- Testy działania w obecności echa, pogłosu i szumów przemysłowych.

Kierunki dalszego rozwoju projektu

Analiza sekwencji zdarzeń

- Wykrywanie wzorców czasowych i zmian stanu maszyny w dłuższym okresie.

Integracja z przemysłem

- Kompatybilność z systemami SCADA, MQTT, Modbus i pracą w czasie rzeczywistym.

Optymalizacja architektury

- Automatyczny dobór struktury i parametrów modelu bez ręcznej ingerencji.

Odporność na zakłócenia

- Testy działania w obecności echa, pogłosu i szumów przemysłowych.

Kierunki dalszego rozwoju projektu

Odporność na zakłócenia

- Testy działania w obecności echa, pogłosu i szumów przemysłowych.

Optymalizacja architektury

- Automatyczny dobór struktury i parametrów modelu bez ręcznej ingerencji.

Integracja z przemysłem

- Kompatybilność z systemami SCADA, MQTT, Modbus i pracą w czasie rzeczywistym.

Analiza sekwencji zdarzeń

- Wykrywanie wzorców czasowych i zmian stanu maszyny w dłuższym okresie.

Wizualizacja działania modelu

- Tryb dydaktyczny: obserwacja sygnałów, aktywacji i decyzji sieci neuronowej.

Gdzie system może znaleźć zastosowanie?

Gdzie system może znaleźć zastosowanie?



Fabryki i przemysł ciężki

- Diagnostyka pomp, silników i linii produkcyjnych bez potrzeby fizycznych czujników.

Gdzie system może znaleźć zastosowanie?



Fabryki i przemysł ciężki

- Diagnostyka pomp, silników i linii produkcyjnych bez potrzeby fizycznych czujników.



Energetyka i turbiny wiatrowe

- Wczesne wykrywanie awarii w turbinach i generatorach — kluczowe dla niezawodności infrastruktury.

Gdzie system może znaleźć zastosowanie?



Fabryki i przemysł ciężki

- Diagnostyka pomp, silników i linii produkcyjnych bez potrzeby fizycznych czujników.



Energetyka i turbiny wiatrowe

- Wczesne wykrywanie awarii w turbinach i generatorach — kluczowe dla niezawodności infrastruktury.



Pojazdy autonomiczne i transport publiczny

- Monitorowanie dźwięków układów jezdnych, silników i zawieszenia w czasie jazdy.

Gdzie system może znaleźć zastosowanie?



Fabryki i przemysł ciężki

- Diagnostyka pomp, silników i linii produkcyjnych bez potrzeby fizycznych czujników.



Energetyka i turbiny wiatrowe

- Wczesne wykrywanie awarii w turbinach i generatorach — kluczowe dla niezawodności infrastruktury.



Pojazdy autonomiczne i transport publiczny

- Monitorowanie dźwięków układów jezdnych, silników i zawieszenia w czasie jazdy.



Rolnictwo precyzyjne

- Akustyczna ocena stanu zdrowia zwierząt oraz sprawności maszyn rolniczych.

Gdzie system może znaleźć zastosowanie?



Fabryki i przemysł ciężki

- Diagnostyka pomp, silników i linii produkcyjnych bez potrzeby fizycznych czujników.




Energetyka i turbiny wiatrowe

- Wczesne wykrywanie awarii w turbinach i generatorach — kluczowe dla niezawodności infrastruktury.




Pojazdy autonomiczne i transport publiczny

- Monitorowanie dźwięków układów jezdnych, silników i zawieszenia w czasie jazdy.



Rolnictwo precyzyjne

- Akustyczna ocena stanu zdrowia zwierząt oraz sprawności maszyn rolniczych.



Systemy bezpieczeństwa i nadzoru

- Detekcja niepokojących dźwięków (chrobotów, pisków, stuków) w serwerowniach, bankach i laboratoriach.



Politechnika
Wrocławska

Dziękuję



HR EXCELLENCE IN RESEARCH